



**Universidad de Las Américas**

**Facultad de Ingeniería y Ciencias Aplicadas**

**Maestría en Inteligencia Artificial Aplicada**

***Sistema inteligente para la predicción del inventario de  
medicamentos y consumibles críticos en la clínica veterinaria  
NovaPet mediante modelos de aprendizaje automático***

**Ricardo David Ayala Andrade**

**Juan Pablo López**

**Ana Estrella**

***10/05/2026***

**Quito, Ecuador**



## Contenido

|                                                                        |           |
|------------------------------------------------------------------------|-----------|
| Resumen.....                                                           | 1         |
| Abstract .....                                                         | 2         |
| 1. Introducción.....                                                   | 3         |
| <b>1.1. Identificación y descripción del problema o necesidad.....</b> | <b>3</b>  |
| <b>1.2. Descripción de la organización .....</b>                       | <b>3</b>  |
| 2. Análisis de posibles soluciones.....                                | 4         |
| <b>2.1. Identificación y selección de la mejor solución .....</b>      | <b>4</b>  |
| <b>2.2. Impacto del proyecto en la sociedad .....</b>                  | <b>6</b>  |
| 3. Objetivos.....                                                      | 7         |
| <b>3.1. Objetivo General .....</b>                                     | <b>7</b>  |
| <b>3.2. Objetivos Específicos .....</b>                                | <b>7</b>  |
| 4. Alcance .....                                                       | 7         |
| <b>4.1. Alcance funcional de la solución seleccionada .....</b>        | <b>7</b>  |
| <b>4.2. Alcance técnico de la solución seleccionada .....</b>          | <b>8</b>  |
| <b>4.3. Limitaciones y restricciones del proyecto .....</b>            | <b>8</b>  |
| 5. Planificación y costos del proyecto.....                            | 9         |
| 5.1. Metodología de desarrollo.....                                    | 9         |
| 5.2. Planificación general del proyecto .....                          | 10        |
| 5.3. Recursos utilizados .....                                         | 10        |
| 5.4. Riesgos identificados y estrategias de mitigación .....           | 11        |
| 6. Descripción de estudios realizados .....                            | 11        |
| 6.1. Inteligencia artificial aplicada a gestión de inventarios .....   | 11        |
| 6.2. Aprendizaje automático y forecasting temporal .....               | 12        |
| 6.3. Interpretabilidad y ética en inteligencia artificial .....        | 13        |
| 7. Desarrollo del proyecto .....                                       | 14        |
| <b>7.1. Diseño de la solución .....</b>                                | <b>14</b> |
| <b>7.2. Desarrollo de la solución.....</b>                             | <b>14</b> |
| <b>7.3. Resultados y Discusión.....</b>                                | <b>15</b> |
| <b>7.4. Implicaciones éticas .....</b>                                 | <b>15</b> |
| 8. Conclusiones y Recomendaciones .....                                | 16        |
| 9. Trabajo futuro.....                                                 | 17        |
| 10. Referencias bibliográficas .....                                   | 19        |
| 11. Anexos .....                                                       | 20        |



## Resumen

La gestión eficiente del inventario representa uno de los principales desafíos operativos dentro de las clínicas veterinarias, especialmente en el control de medicamentos y consumibles críticos cuya disponibilidad impacta directamente la continuidad de atención y la calidad del servicio. En este contexto, NovaPet enfrentaba dificultades para anticipar el comportamiento de la demanda semanal, generando riesgos asociados a quiebres de stock, compras urgentes, sobre inventario y decisiones altamente dependientes de criterios manuales.

El presente proyecto desarrolla un sistema inteligente de apoyo a la decisión para la predicción del inventario de medicamentos y consumibles críticos mediante modelos de aprendizaje automático. La investigación se estructuró bajo la metodología CRISP-DM, integrando las fases de comprensión del negocio, preparación de datos, modelado, evaluación y despliegue funcional del prototipo. Para ello, se utilizó información histórica real proveniente del Kardex operativo de NovaPet, consolidando variables temporales y patrones de consumo semanal.

Como parte del análisis experimental, se evaluaron tres enfoques predictivos: un modelo baseline basado en promedio móvil de cuatro semanas, Random Forest y XGBoost. La validación se realizó mediante hold-out temporal y walk-forward validation, utilizando métricas MAE, RMSE y  $R^2$  para comparar el desempeño de los modelos. Los resultados evidenciaron que el baseline presentó el mejor desempeño predictivo, alcanzando un MAE de 1.797 y un  $R^2$  de 0.583, superando a los modelos de machine learning más complejos. No obstante, Random Forest se mantuvo como referencia experimental secundaria debido a su capacidad de interpretabilidad y análisis de comportamiento mediante SHAP.

Adicionalmente, se desarrolló un prototipo funcional en Streamlit orientado a usuarios no técnicos, incorporando criterios de experiencia de usuario, validación operativa e interpretabilidad de resultados. El sistema permite proyectar demanda semanal, calcular stock objetivo, estimar compras sugeridas y visualizar riesgos operativos de abastecimiento.

Finalmente, el proyecto evidencia que, en escenarios con patrones temporales relativamente estables y datasets moderados, modelos simples y robustos pueden superar arquitecturas más complejas, resaltando la importancia de la validación temporal, la interpretabilidad y la alineación entre inteligencia artificial y contexto organizacional.

Palabras clave: inteligencia artificial, predicción de demanda, inventario veterinario, aprendizaje automático, Random Forest, baseline, Streamlit, analítica predictiva.



## **Abstract**

Efficient inventory management represents one of the main operational challenges within veterinary clinics, particularly regarding critical medications and consumables whose availability directly impacts service continuity and quality of care. In this context, NovaPet faced difficulties in anticipating weekly demand behavior, generating risks associated with stockouts, urgent purchases, overstocking, and decision-making processes highly dependent on manual judgment.

This project develops an intelligent decision-support system for predicting the inventory of critical medications and consumables through machine learning models. The research was structured under the CRISP-DM methodology, integrating the phases of business understanding, data preparation, modeling, evaluation, and functional prototype deployment. Historical operational Kardex data from NovaPet was used to consolidate temporal variables and weekly consumption patterns.

As part of the experimental analysis, three predictive approaches were evaluated: a baseline model based on a four-week moving average, Random Forest, and XGBoost. Validation was performed using temporal hold-out and walk-forward validation, employing MAE, RMSE, and  $R^2$  metrics to compare model performance. Results demonstrated that the baseline model achieved the best predictive performance, reaching an MAE of 1.797 and an  $R^2$  of 0.583, outperforming the more complex machine learning models. Nevertheless, Random Forest was maintained as a secondary experimental reference due to its interpretability capabilities and behavioral analysis through SHAP.

Additionally, a functional Streamlit prototype was developed for non-technical users, incorporating usability, operational validation, and result interpretability criteria. The system allows users to project weekly demand, calculate target stock, estimate recommended purchases, and visualize operational supply risks.

Finally, the project demonstrates that, in scenarios with stable temporal patterns and moderate datasets, simple and robust models can outperform more complex architectures, highlighting the importance of temporal validation, interpretability, and alignment between artificial intelligence and organizational context.

**Keywords:** artificial intelligence, demand forecasting, veterinary inventory, machine learning, Random Forest, baseline model, Streamlit, predictive analytics.



## **1. Introducción**

### **1.1. Identificación y descripción del problema o necesidad**

La gestión de inventario constituye un factor crítico dentro de las operaciones de clínicas veterinarias, debido a que la disponibilidad oportuna de medicamentos, vacunas y consumibles impacta directamente la continuidad de atención, la calidad del servicio y la capacidad de respuesta ante emergencias médicas. En este contexto, NovaPet enfrentaba dificultades para anticipar de manera precisa el comportamiento de la demanda semanal de productos críticos, generando escenarios frecuentes de quiebres de stock, compras urgentes, sobreinventario y dependencia de decisiones manuales basadas principalmente en experiencia operativa.

La ausencia de herramientas predictivas estructuradas limitaba la capacidad de planificación del abastecimiento y aumentaba el riesgo financiero asociado a inventarios inmovilizados o reposiciones tardías. Adicionalmente, la variabilidad de consumo entre medicamentos y vacunas dificultaba establecer políticas de compra consistentes, especialmente en productos con alta sensibilidad operativa o demanda fluctuante.

Frente a esta problemática, surge la necesidad de implementar mecanismos de apoyo a la decisión que permitan anticipar tendencias de consumo y fortalecer la planificación de inventario mediante el uso de inteligencia artificial y analítica predictiva. En este sentido, los modelos de aprendizaje automático representan una alternativa relevante para identificar patrones históricos de demanda y transformar datos operativos en información útil para la toma de decisiones.

El presente proyecto propone el desarrollo de un sistema inteligente para la predicción del inventario de medicamentos y consumibles críticos en NovaPet mediante modelos de aprendizaje automático. El objetivo es construir un prototipo funcional capaz de estimar el consumo esperado de productos críticos y generar recomendaciones de compra basadas en evidencia cuantitativa, contribuyendo a reducir riesgos operativos y mejorar la eficiencia de abastecimiento.

Para ello, se utilizó información histórica real proveniente del Kardex operativo de la clínica veterinaria, integrando procesos de preparación de datos, validación temporal, evaluación comparativa de modelos y despliegue de un prototipo interactivo mediante Streamlit. El proyecto incorpora además criterios de interpretabilidad, robustez y consideraciones éticas orientadas al uso responsable de sistemas de inteligencia artificial en entornos organizacionales.

### **1.2. Descripción de la organización**

NovaPet es una clínica veterinaria dedicada a la atención médica integral de mascotas, ofreciendo servicios de consulta, vacunación, tratamientos especializados y comercialización de medicamentos y consumibles veterinarios. Como parte de su operación diaria, la organización administra un inventario de productos críticos cuya disponibilidad resulta esencial para garantizar continuidad operativa y atención oportuna a los pacientes.



Dentro de este contexto, la gestión de inventario representa un proceso estratégico debido a la sensibilidad operativa asociada a medicamentos, vacunas y suministros clínicos. La disponibilidad insuficiente de productos puede provocar interrupciones en tratamientos, retrasos en atención médica y necesidad de compras urgentes, mientras que el exceso de inventario incrementa costos de almacenamiento, capital inmovilizado y riesgo de caducidad de productos.

Previo al desarrollo del presente proyecto, la planificación de abastecimiento en NovaPet se realizaba principalmente mediante revisión manual de consumos históricos y criterio operativo del personal administrativo, sin disponer de herramientas predictivas automatizadas capaces de anticipar patrones de demanda. Esta situación generaba limitaciones en la precisión de compra y reducía la capacidad de reacción frente a cambios de consumo.

A nivel tecnológico, la organización contaba con registros históricos almacenados en Kardex operativos, los cuales constituyeron la principal fuente de información para el desarrollo del sistema inteligente propuesto. A partir de estos datos, se identificó la oportunidad de implementar un enfoque basado en aprendizaje automático que permitiera transformar información transaccional en proyecciones de demanda útiles para la toma de decisiones.

El proyecto se alinea con la necesidad organizacional de fortalecer la gestión operativa mediante herramientas de inteligencia artificial aplicadas, buscando no solo mejorar la precisión de abastecimiento, sino también promover una cultura de toma de decisiones basada en datos. Asimismo, la propuesta permite explorar el potencial de la analítica predictiva en pequeñas y medianas organizaciones del sector veterinario, donde la adopción de soluciones de inteligencia artificial aún presenta oportunidades significativas de crecimiento.

## **2. Análisis de posibles soluciones**

### **2.1. Identificación y selección de la mejor solución**

#### **Alternativa A: Modelo Random Forest Regressor (scikit-learn)**

Descripción: Modelo basado en múltiples árboles de decisión que combina sus predicciones para mejorar precisión y reducir sobreajuste. Es robusto ante datos heterogéneos y funciona bien con muestras pequeñas y medianas.

Alcance:

- Predicción del consumo por categoría y por insumo específico.
- Identificación de variables más relevantes (feature importance).

Tecnologías: Python, scikit-learn, pandas, Streamlit.



### Alternativa B: Modelo XGBoost Regressor

Descripción: Modelo de boosting que optimiza iterativamente árboles de regresión. Destaca por su capacidad para capturar patrones no lineales y ofrecer mayor precisión en escenarios con variabilidad en la demanda.

Alcance:

- Mejora del rendimiento en comparación con Random Forest.
- Ajustes finos a través de hiperparámetros.

Tecnologías: Python, XGBoost (API compatible con scikit-learn), Streamlit.

| Característica           | Peso | Random Forest | XGBoost  |
|--------------------------|------|---------------|----------|
| Precisión del modelo     | 30%  | Alta          | Muy alta |
| Robustez                 | 25%  | Muy alta      | Alta     |
| Eficiencia computacional | 15%  | Alta          | Media    |
| Mantenibilidad           | 15%  | Alta          | Media    |
| Interpretabilidad        | 15%  | Alta          | Media    |

La ponderación asignada a cada característica del modelo se basa en las necesidades reales de NovaPet y en los criterios del estándar ISO/IEC 25010. La precisión del modelo (30%) recibe el mayor peso porque la utilidad del sistema depende directamente de la exactitud con la que prediga el consumo futuro; un error elevado generaría quiebres de stock o sobre inventario. La robustez (25%) también es prioritaria, ya que el consumo de insumos veterinarios es variable y el modelo debe comportarse de manera estable ante fluctuaciones o pocos datos. La eficiencia computacional (15%) tiene importancia moderada porque la clínica no cuenta con infraestructura avanzada y se requiere un modelo que pueda ejecutarse rápidamente en equipos básicos. La mantenibilidad (15%) es relevante para garantizar que el sistema pueda actualizarse fácilmente conforme NovaPet crezca y se registren nuevos datos. Finalmente, la interpretabilidad (15%) se pondera para asegurar que el personal pueda comprender por qué el modelo recomienda ciertos niveles de reposición, facilitando la toma de decisiones y aumentando la confianza en el sistema. Estas ponderaciones reflejan un equilibrio entre desempeño técnico, operación práctica y continuidad del sistema en un entorno real.

Resultado esperado: XGBoost ofrecerá mejor precisión, mientras Random Forest será más estable e interpretable. La selección final del modelo se realizará mediante un procedimiento formal de evaluación comparativa. Se definirá un modelo de línea base basado en promedio móvil de cuatro semanas. La métrica principal de decisión será el Error Absoluto Medio (MAE). El modelo seleccionado deberá demostrar una mejora mínima del 15% frente a la línea base y presentar  $R^2$  positivo en el conjunto de prueba. En caso de diferencia menor al 5% entre modelos, se priorizará el de mayor estabilidad entre entrenamiento y validación temporal.



## **2.2. Impacto del proyecto en la sociedad**

El desarrollo de sistemas inteligentes aplicados a la gestión operativa representa una oportunidad significativa para fortalecer la eficiencia, sostenibilidad y capacidad de respuesta de organizaciones de distintos sectores, incluyendo servicios de salud veterinaria. En este contexto, el proyecto desarrollado para NovaPet no solo busca optimizar procesos internos de abastecimiento, sino también generar un impacto positivo sobre los diferentes actores relacionados con la operación clínica, contribuyendo a mejorar continuidad de atención, calidad de servicio y capacidad de planificación organizacional.

Para analizar el impacto del proyecto se utilizó un enfoque combinado de Evaluación de Impacto Social (EIS) y Stakeholder Mapping, identificando los principales grupos involucrados y los posibles efectos positivos y riesgos asociados a la implementación del sistema inteligente.

En primer lugar, el principal grupo beneficiado corresponde a los pacientes veterinarios y sus propietarios, quienes dependen indirectamente de la disponibilidad oportuna de medicamentos y consumibles críticos para recibir atención adecuada. La reducción de quiebres de stock contribuye a disminuir retrasos en tratamientos, reprogramaciones y limitaciones de atención clínica, fortaleciendo así la continuidad del servicio veterinario.

A nivel organizacional, el sistema genera beneficios sobre el personal administrativo y operativo de NovaPet al reducir la dependencia de revisiones manuales de inventario y facilitar la toma de decisiones basada en datos. Esto permite optimizar tiempo operativo, disminuir carga administrativa y mejorar capacidad de planificación de compras. Asimismo, la incorporación de herramientas de analítica predictiva fortalece el proceso de transformación digital de la organización y promueve una cultura orientada a decisiones fundamentadas en evidencia cuantitativa.

Desde una perspectiva económica, el proyecto tiene potencial para contribuir a la reducción de costos asociados a compras urgentes, desperdicio por caducidad de productos y capital inmovilizado en inventario excesivo. Esto resulta especialmente relevante en pequeñas y medianas organizaciones, donde la eficiencia operativa impacta directamente la sostenibilidad financiera.

En términos tecnológicos y académicos, el proyecto evidencia la aplicabilidad de inteligencia artificial en entornos organizacionales reales de tamaño moderado, demostrando que técnicas de analítica predictiva pueden implementarse incluso con datasets relativamente pequeños cuando existe adecuada validación metodológica y alineación con el contexto operativo.

No obstante, también se identifican riesgos potenciales asociados al uso de sistemas inteligentes. Entre ellos destacan la posible dependencia excesiva del sistema, el riesgo de automatizar decisiones sin supervisión humana y la propagación de errores derivados de datos incompletos o inconsistentes dentro del Kardex. Por esta razón, el prototipo fue diseñado explícitamente como una herramienta de apoyo a la decisión y no como un mecanismo de automatización total de compras o abastecimiento.





Finalmente, el proyecto promueve un enfoque de inteligencia artificial responsable, priorizando interpretabilidad, transparencia y supervisión humana sobre automatización absoluta. Esto permite equilibrar innovación tecnológica con criterios éticos y operativos acordes al contexto organizacional de NovaPet.

### **3. Objetivos**

#### **3.1. Objetivo General**

Desarrollar un sistema inteligente para la predicción del inventario de medicamentos y consumibles críticos en la clínica veterinaria NovaPet mediante modelos de aprendizaje automático, con el fin de estimar el consumo semanal esperado y generar recomendaciones de abastecimiento basadas en datos históricos y validación técnica cuantificable.

#### **3.2. Objetivos Específicos**

- Recolectar, consolidar y preparar datos históricos provenientes del Kardex operativo de NovaPet, garantizando consistencia y calidad mínima de registros para el desarrollo del modelo predictivo.
- Generar variables derivadas temporales, incluyendo rezagos de consumo, promedios móviles y características semanales, que permitan representar patrones históricos de demanda.
- Implementar un modelo baseline basado en promedio móvil de cuatro semanas como referencia inicial de comparación predictiva.
- Entrenar y evaluar modelos de aprendizaje automático supervisado, específicamente Random Forest y XGBoost, mediante validación temporal hold-out y walk-forward validation.
- Comparar el desempeño de los modelos utilizando métricas MAE, RMSE y  $R^2$  para determinar la alternativa más robusta y coherente con el comportamiento operativo observado.
- Desarrollar un prototipo funcional mediante Streamlit que permita visualizar predicciones, calcular recomendaciones de compra y facilitar la interpretación operativa de resultados.
- Incorporar criterios de interpretabilidad, validación y uso responsable de inteligencia artificial dentro del diseño metodológico y funcional del sistema.

### **4. Alcance**

#### **4.1. Alcance funcional de la solución seleccionada**

El proyecto contempla el desarrollo de un sistema inteligente orientado a la predicción del consumo semanal de medicamentos y consumibles críticos dentro de la clínica veterinaria NovaPet. El sistema utiliza información histórica proveniente del Kardex institucional para generar estimaciones de demanda y recomendaciones de compra orientadas a reducir riesgos de desabastecimiento y mejorar la planificación operativa.



El alcance funcional incluye las fases de recolección y preparación de datos, generación de variables temporales, entrenamiento y evaluación de modelos predictivos, validación técnica mediante técnicas temporales y despliegue de un prototipo funcional desarrollado en Streamlit.

Aunque el proyecto se enmarca conceptualmente en la gestión inteligente de medicamentos y consumibles críticos, el componente predictivo fue aplicado prioritariamente sobre ítems con histórico transaccional suficiente dentro del Kardex institucional, particularmente medicamentos y vacunas. En el caso de consumibles con baja trazabilidad histórica o comportamiento más estable, se consideró inicialmente una gestión mediante reglas operativas de stock mínimo y reposición básica. Esta decisión permitió mantener coherencia metodológica, priorizar la calidad del modelado y enfocar el alcance del MVP en productos con mayor impacto operativo y mejor capacidad predictiva.

El prototipo desarrollado permite seleccionar productos desde una interfaz interactiva, ingresar consumos recientes, estimar demanda futura, calcular stock objetivo y visualizar recomendaciones operativas de abastecimiento. Asimismo, incorpora mecanismos de comparación experimental entre el modelo baseline y Random Forest, además de visualizaciones orientadas a mejorar interpretabilidad y experiencia de usuario.

#### **4.2. Alcance técnico de la solución seleccionada**

A nivel técnico, el proyecto se desarrolló utilizando Python como lenguaje principal, integrando librerías de análisis y aprendizaje automático como Pandas, NumPy, Scikit-learn, XGBoost y Matplotlib. El despliegue funcional del prototipo se realizó mediante Streamlit Cloud.

El modelado predictivo se enfocó en técnicas supervisadas aplicadas sobre series temporales estructuradas, utilizando variables históricas de consumo semanal, rezagos temporales y atributos derivados del comportamiento del Kardex.

La validación metodológica incluyó técnicas de hold-out temporal y walk-forward validation para preservar secuencia cronológica y evitar fuga de información. La evaluación comparativa se realizó utilizando métricas MAE, RMSE y  $R^2$ .

Adicionalmente, se incorporaron técnicas de interpretabilidad mediante SHAP para analizar el impacto relativo de variables dentro del modelo Random Forest, fortaleciendo transparencia y comprensión del comportamiento predictivo.

#### **4.3. Limitaciones y restricciones del proyecto**

El proyecto presenta ciertas limitaciones relacionadas principalmente con disponibilidad y naturaleza de los datos históricos utilizados. El dataset disponible posee un horizonte temporal moderado, lo que restringe la capacidad de capturar patrones estacionales complejos o comportamientos de largo plazo.

Asimismo, el modelo no incorpora actualmente variables externas como campañas veterinarias, número de consultas médicas, estacionalidad climática, promociones



comerciales o eventos extraordinarios que podrían influir sobre el comportamiento real de la demanda.

Otra limitación relevante corresponde a la dependencia de calidad del Kardex institucional, ya que inconsistencias, registros faltantes o errores operativos pueden afectar directamente precisión predictiva y estabilidad del sistema.

Finalmente, el prototipo desarrollado corresponde a un MVP funcional orientado a validación técnica y operativa preliminar, por lo que no incluye todavía integración automática con otros sistemas como ERPs, bases de datos en tiempo real ni mecanismos automatizados de reentrenamiento continuo del modelo.

## **5. Planificación y costos del proyecto**

### **5.1. Metodología de desarrollo**

El desarrollo del proyecto se estructuró bajo la metodología CRISP-DM (Cross Industry Standard Process for Data Mining), ampliamente utilizada en proyectos de analítica predictiva e inteligencia artificial debido a su enfoque iterativo, organizado y orientado a negocio. Esta metodología permitió mantener trazabilidad entre la problemática organizacional identificada en NovaPet y las decisiones técnicas adoptadas durante el desarrollo del sistema inteligente.

La primera fase, comprensión del negocio, se enfocó en analizar la problemática asociada a la gestión manual del inventario, identificando riesgos operativos relacionados con quiebres de stock, compras urgentes y sobreinventario. En esta etapa se definieron los objetivos organizacionales y los criterios de éxito del proyecto.

Posteriormente, en la fase de comprensión de datos, se analizaron los registros históricos provenientes del Kardex institucional, evaluando estructura, calidad, frecuencia de consumo y disponibilidad de variables relevantes para el modelado predictivo.

La fase de preparación de datos incluyó limpieza de registros, consolidación de información semanal, tratamiento de inconsistencias y generación de variables derivadas temporales como rezagos de consumo, promedios móviles y características semanales. Esta etapa fue fundamental para transformar datos operativos en un conjunto estructurado apto para entrenamiento supervisado.

En la fase de modelado se implementaron y compararon distintos enfoques predictivos, incluyendo un baseline basado en promedio móvil de cuatro semanas, Random Forest y XGBoost. El objetivo fue evaluar el comportamiento de modelos simples y complejos bajo condiciones reales de operación.

La fase de evaluación incorporó técnicas de validación temporal hold-out y walk-forward validation, utilizando métricas MAE, RMSE y  $R^2$  para analizar precisión, estabilidad y capacidad predictiva. Asimismo, se aplicaron técnicas de interpretabilidad mediante SHAP para comprender el impacto relativo de las variables utilizadas por el modelo Random Forest.



Finalmente, la fase de despliegue contempló el desarrollo de un prototipo funcional mediante Streamlit, permitiendo visualizar resultados predictivos, recomendaciones operativas y comparaciones experimentales dentro de una interfaz orientada a usuarios no técnicos.

## **5.2. Planificación general del proyecto**

El proyecto se desarrolló de manera progresiva a lo largo de distintas etapas técnicas y metodológicas, iniciando con el análisis organizacional del problema y finalizando con la construcción del prototipo funcional y documentación final del sistema.

Inicialmente se realizó el levantamiento de información operativa y comprensión de necesidades de NovaPet, identificando riesgos asociados a gestión de inventario y disponibilidad de datos históricos. Posteriormente se ejecutaron procesos de limpieza, estructuración y preparación de datos provenientes del Kardex institucional.

Una vez consolidado el dataset, se desarrolló la fase experimental de modelado predictivo, implementando baseline, Random Forest y XGBoost bajo criterios de validación temporal. Posteriormente se analizaron métricas comparativas y comportamiento de modelos para seleccionar el enfoque operativo principal del prototipo.

En las etapas finales se incorporaron mecanismos de interpretabilidad mediante SHAP, validación robusta mediante walk-forward validation y desarrollo del prototipo interactivo en Streamlit, incluyendo mejoras progresivas orientadas a experiencia de usuario, visualización e interpretación operativa.

Finalmente, se ejecutó la consolidación documental del proyecto, integración de anexos técnicos, elaboración de evidencias de validación y preparación de materiales de presentación y defensa académica.

## **5.3. Recursos utilizados**

El desarrollo del proyecto requirió recursos tecnológicos, metodológicos y computacionales orientados al procesamiento de datos, entrenamiento de modelos y despliegue funcional del prototipo.

A nivel de software, se utilizó Python como lenguaje principal de programación debido a su amplio ecosistema de librerías orientadas a ciencia de datos e inteligencia artificial. Las principales herramientas utilizadas fueron Pandas y NumPy para manipulación de datos, Scikit-learn para entrenamiento de modelos supervisados, XGBoost para boosting avanzado, Matplotlib para visualización y Streamlit para construcción de la interfaz interactiva.

El desarrollo experimental y validación de modelos se realizó mediante notebooks ejecutados en entornos compatibles con Python, mientras que el despliegue preliminar del prototipo se implementó en Streamlit Cloud para facilitar accesibilidad y demostración funcional.



A nivel de información, el principal recurso utilizado correspondió a los registros históricos del Kardex institucional de NovaPet, los cuales proporcionaron evidencia transaccional necesaria para el análisis de patrones de consumo y construcción del dataset predictivo.

En términos metodológicos, el proyecto se apoyó en literatura científica relacionada con forecasting, analítica predictiva, gestión de inventarios e interpretabilidad de modelos de inteligencia artificial, permitiendo fundamentar técnicamente las decisiones adoptadas durante el desarrollo.

#### **5.4. Riesgos identificados y estrategias de mitigación**

Durante el desarrollo del proyecto se identificaron distintos riesgos técnicos, operativos y metodológicos que podían afectar estabilidad, confiabilidad o utilidad del sistema inteligente propuesto.

Uno de los principales riesgos correspondía a la calidad y consistencia de los datos históricos del Kardex institucional. Registros incompletos, inconsistentes o insuficientes podían afectar precisión predictiva y generar sesgos dentro del entrenamiento supervisado. Para mitigar este riesgo se implementaron procesos de limpieza, validación y consolidación de datos antes del modelado.

Otro riesgo relevante correspondía al sobreajuste de modelos complejos debido al tamaño moderado del dataset disponible. Para reducir esta posibilidad se aplicaron técnicas de validación temporal, comparación contra baseline y evaluación mediante walk-forward validation, priorizando estabilidad y capacidad de generalización sobre complejidad algorítmica.

También se identificó el riesgo de interpretar el sistema como un mecanismo de automatización total de decisiones de compra. Para evitarlo, el prototipo fue diseñado explícitamente como una herramienta de apoyo a la decisión, manteniendo supervisión humana como componente obligatorio dentro del proceso operativo.

Desde una perspectiva organizacional, se consideró la posibilidad de resistencia al uso de herramientas basadas en inteligencia artificial debido a falta de familiaridad tecnológica. En respuesta, el diseño del prototipo priorizó interpretabilidad, simplicidad visual y experiencia de usuario orientada a personal no técnico.

Finalmente, se reconoció el riesgo asociado a dependencia futura del comportamiento histórico del Kardex, especialmente frente a cambios operativos o eventos no observados previamente. Por esta razón, el proyecto contempla futuras líneas de mejora relacionadas con ampliación del dataset, incorporación de variables externas y monitoreo continuo del desempeño predictivo.

### **6. Descripción de estudios realizados**

#### **6.1. Inteligencia artificial aplicada a gestión de inventarios**

La aplicación de inteligencia artificial en procesos de gestión de inventario ha experimentado un crecimiento significativo durante los últimos años debido a la



necesidad organizacional de mejorar precisión de abastecimiento, reducir costos operativos y fortalecer capacidad de respuesta frente a variaciones de demanda. Diversos estudios demuestran que las técnicas de analítica predictiva y aprendizaje automático permiten identificar patrones históricos de consumo y transformar información operativa en apoyo estratégico para la toma de decisiones (Choi et al., 2018; Carboneau et al., 2008).

Dentro del contexto de forecasting de demanda, los modelos de machine learning han sido utilizados para estimar comportamiento futuro de productos mediante análisis de series temporales, variables históricas y características derivadas del comportamiento transaccional. Entre los enfoques más utilizados destacan Random Forest, XGBoost, redes neuronales y modelos híbridos orientados a optimizar precisión predictiva en distintos sectores industriales y comerciales (Makridakis et al., 2018).

En el ámbito de gestión de inventarios, la inteligencia artificial permite reducir riesgos asociados a quiebres de stock, compras urgentes y sobreinventario mediante sistemas capaces de anticipar tendencias de consumo y recomendar niveles óptimos de abastecimiento. Estas capacidades resultan especialmente relevantes en organizaciones donde la disponibilidad de productos impacta directamente continuidad operativa y calidad del servicio (Waller & Fawcett, 2013).

No obstante, diversos autores señalan que la complejidad algorítmica no garantiza necesariamente mejores resultados predictivos. En escenarios con datasets moderados o patrones relativamente estables, modelos simples y robustos pueden superar enfoques avanzados, particularmente cuando se prioriza interpretabilidad, estabilidad y capacidad de generalización (Makridakis et al., 2022).

Asimismo, la literatura reciente enfatiza la importancia de incorporar mecanismos de interpretabilidad y validación temporal dentro de proyectos de inteligencia artificial aplicada. Técnicas como SHAP, validación walk-forward y hold-out temporal permiten fortalecer transparencia, reducir riesgos metodológicos y mejorar confianza organizacional en los resultados obtenidos (Molnar, 2022).

## **6.2. Aprendizaje automático y forecasting temporal**

El forecasting temporal constituye una de las aplicaciones más relevantes del aprendizaje automático dentro de entornos organizacionales, debido a su capacidad para estimar comportamiento futuro a partir de patrones históricos observados en secuencias cronológicas. Según Hyndman y Athanasopoulos (2021), la correcta modelación temporal requiere preservar la secuencia cronológica de los datos y evitar técnicas de validación que introduzcan fuga de información.

En problemas de predicción de demanda, las variables temporales adquieren especial importancia porque el comportamiento reciente suele contener información relevante para anticipar consumo futuro. Por esta razón, múltiples investigaciones utilizan rezagos temporales, promedios móviles y tendencias históricas como variables explicativas dentro de modelos supervisados (Box et al., 2015).



Dentro de los algoritmos evaluados en este proyecto, Random Forest representa un enfoque basado en ensamblaje de árboles de decisión capaz de modelar relaciones no lineales y reducir sobreajuste mediante agregación de múltiples estimadores. Su principal ventaja radica en la robustez frente a ruido y capacidad de interpretabilidad mediante análisis de importancia de variables (Breiman, 2001).

Por otro lado, XGBoost corresponde a un algoritmo de boosting optimizado que construye secuencialmente modelos orientados a corregir errores previos. Este enfoque ha demostrado alto desempeño en numerosos problemas estructurados de machine learning, aunque su comportamiento depende considerablemente de calidad de datos, volumen histórico y ajuste de hiperparámetros (Chen & Guestrin, 2016).

A pesar de la popularidad de modelos complejos, la literatura también reconoce el valor de enfoques baseline como promedio móvil, especialmente en escenarios con estabilidad relativa o comportamiento predominantemente dependiente de consumo reciente. Estos modelos ofrecen alta interpretabilidad, simplicidad operativa y menor sensibilidad frente a datasets reducidos (Makridakis et al., 2018).

En este proyecto, la comparación entre baseline, Random Forest y XGBoost permitió analizar cómo distintos niveles de complejidad algorítmica responden frente a un problema real de forecasting veterinario, priorizando no solo precisión predictiva, sino también robustez metodológica y utilidad operativa.

### **6.3. Interpretabilidad y ética en inteligencia artificial**

Uno de los principales desafíos actuales en proyectos de inteligencia artificial aplicada corresponde a la necesidad de garantizar transparencia e interpretabilidad dentro de los sistemas predictivos. En entornos organizacionales, especialmente aquellos vinculados a procesos críticos de decisión, resulta fundamental comprender cómo y por qué un modelo genera determinadas predicciones (Floridi et al., 2018).

La interpretabilidad permite identificar variables relevantes, detectar posibles sesgos y fortalecer confianza de usuarios finales sobre el comportamiento del sistema. En este contexto, técnicas como SHAP (SHapley Additive exPlanations) han ganado relevancia debido a su capacidad para explicar el impacto individual de variables dentro de modelos complejos de machine learning (Lundberg & Lee, 2017).

La literatura especializada también enfatiza que la implementación de sistemas inteligentes debe considerar principios éticos relacionados con supervisión humana, uso responsable de automatización y mitigación de riesgos derivados de datos históricos sesgados o incompletos. Un sistema predictivo no debe reemplazar completamente criterio humano, especialmente cuando las decisiones poseen impacto operativo o económico relevante (Russell & Norvig, 2021).

Adicionalmente, múltiples investigaciones destacan la importancia de validar adecuadamente los modelos para evitar fuga de información y falsas expectativas de desempeño. En problemas temporales, el uso incorrecto de validación aleatoria puede generar resultados artificialmente optimistas que no representan condiciones reales de operación (Hyndman & Athanasopoulos, 2021).





Por esta razón, el presente proyecto incorporó criterios de interpretabilidad mediante SHAP, validación temporal y enfoque explícito de apoyo a la decisión, priorizando transparencia y utilidad organizacional sobre automatización total. Esta aproximación busca equilibrar innovación tecnológica con responsabilidad metodológica y operativa dentro del contexto veterinario de NovaPet.

## **7. Desarrollo del proyecto**

El desarrollo del proyecto se orientó a la construcción de un sistema inteligente capaz de apoyar la predicción del inventario de medicamentos y consumibles críticos en NovaPet mediante modelos de aprendizaje automático. Para ello, se aplicó una metodología estructurada basada en CRISP-DM, integrando análisis organizacional, preparación de datos, modelado predictivo, validación temporal y despliegue funcional del prototipo.

### **7.1. Diseño de la solución**

El proyecto se desarrolló siguiendo las fases de la metodología CRISP-DM, iniciando con la comprensión del problema organizacional relacionado con la gestión manual del inventario y los riesgos asociados a quiebres de stock, compras urgentes y sobreinventario. Posteriormente, se realizó el análisis y preparación de los datos históricos provenientes del Kardex institucional de NovaPet.

Durante el desarrollo se ejecutaron actividades de limpieza de datos, generación de variables temporales, entrenamiento de modelos predictivos y validación mediante técnicas temporales. Adicionalmente, se incorporaron mecanismos de interpretabilidad y visualización orientados a fortalecer comprensión y confianza sobre los resultados obtenidos.

Las principales herramientas utilizadas fueron Python, Pandas, NumPy, Scikit-learn, XGBoost, Matplotlib y Streamlit. La evaluación del sistema se realizó utilizando métricas MAE, RMSE y  $R^2$ , complementadas con validación hold-out temporal y walk-forward validation para preservar coherencia cronológica y reducir riesgos de fuga de información.

### **7.2. Desarrollo de la solución**

La solución fue desarrollada utilizando registros históricos del Kardex operativo de NovaPet, consolidando consumos semanales de medicamentos y productos críticos. Como parte del preprocesamiento se ejecutaron actividades de limpieza, estandarización y generación de variables derivadas como rezagos temporales, promedios móviles y tendencias recientes.

Para el modelado predictivo se evaluaron tres enfoques distintos: un baseline basado en promedio móvil de cuatro semanas, Random Forest y XGBoost. El baseline fue utilizado como referencia inicial debido a su simplicidad e interpretabilidad, mientras que Random Forest y XGBoost fueron incorporados como alternativas de machine learning supervisado para analizar relaciones más complejas dentro de los datos.

Los resultados obtenidos evidenciaron que el baseline presentó el mejor desempeño general bajo las condiciones actuales del dataset, razón por la cual fue seleccionado





como motor principal del prototipo funcional. No obstante, Random Forest se mantuvo como referencia experimental secundaria debido a su capacidad de interpretabilidad mediante SHAP y valor metodológico para comparación de modelos.

El despliegue del sistema se realizó mediante Streamlit Cloud, desarrollando una interfaz interactiva orientada a usuarios no técnicos. El prototipo permite seleccionar productos, ingresar consumos recientes, proyectar demanda semanal y generar recomendaciones operativas de abastecimiento.

### 7.3. Resultados y Discusión.

Los resultados obtenidos demostraron que el sistema fue capaz de generar predicciones funcionales de demanda semanal y recomendaciones operativas de inventario utilizando información histórica real del Kardex institucional. La evaluación comparativa evidenció que el modelo baseline alcanzó el mejor desempeño predictivo, obteniendo un MAE de 1.797 y un  $R^2$  de 0.583, superando a Random Forest y XGBoost.

Uno de los principales hallazgos del proyecto fue identificar que el comportamiento reciente del consumo posee una fuerte influencia sobre la demanda futura dentro del contexto operativo de NovaPet. Esto explica por qué un enfoque simple basado en promedio móvil logró superar a modelos de mayor complejidad algorítmica.

Adicionalmente, las pruebas de validación temporal y walk-forward validation permitieron verificar estabilidad y coherencia del sistema bajo escenarios cronológicos progresivos. El análisis SHAP aplicado sobre Random Forest confirmó que variables temporales como lag\_2, lag\_3 y tendencias recientes representan los principales factores explicativos dentro del proceso predictivo.

Desde una perspectiva práctica, el desarrollo del prototipo en Streamlit permitió transformar los resultados del modelo en una herramienta interactiva y comprensible para usuarios no técnicos. La incorporación de funcionalidades orientadas a experiencia de usuario, visualización de riesgo e interpretación operativa fortaleció la aplicabilidad organizacional del sistema.

**Tabla 1: Comparación de desempeño de modelos predictivos**

| Modelo                              | MAE   | RMSE  | $R^2$ |
|-------------------------------------|-------|-------|-------|
| Baseline (Promedio móvil 4 semanas) | 1.797 | 3.067 | 0.583 |
| Random Forest                       | 2.178 | 4.139 | 0.241 |
| XGBoost                             | 2.559 | 4.148 | 0.238 |

### 7.4. Implicaciones éticas

El desarrollo del proyecto consideró principios de uso responsable e inteligencia artificial ética, reconociendo que las decisiones asociadas a gestión de inventario pueden generar impactos operativos y económicos relevantes dentro de NovaPet.



Uno de los principales riesgos identificados corresponde a la dependencia excesiva del sistema predictivo y a la posibilidad de automatizar decisiones sin supervisión humana. Por esta razón, el prototipo fue diseñado explícitamente como una herramienta de apoyo a la decisión y no como un mecanismo autónomo de abastecimiento.

Asimismo, se reconoció que la calidad de las predicciones depende directamente de la consistencia del Kardex institucional, por lo que errores históricos o registros incompletos podrían afectar comportamiento del sistema. En respuesta, el proyecto priorizó transparencia, interpretabilidad y validación temporal como mecanismos para fortalecer confianza y reducir riesgos metodológicos asociados al uso de inteligencia artificial aplicada.

También se consideró la importancia de evitar “sobre-promesas” asociadas a inteligencia artificial. El proyecto reconoce explícitamente sus limitaciones actuales, incluyendo horizonte histórico moderado, ausencia de variables externas y necesidad de monitoreo continuo del desempeño predictivo.

Finalmente, el enfoque adoptado busca promover una implementación responsable de inteligencia artificial aplicada, equilibrando innovación tecnológica, utilidad organizacional y supervisión humana dentro del contexto operativo de NovaPet.

## **8. Conclusiones y Recomendaciones**

El presente proyecto permitió desarrollar un sistema inteligente orientado a la predicción del inventario de medicamentos y consumibles críticos en la clínica veterinaria NovaPet mediante modelos de aprendizaje automático, integrando componentes de analítica predictiva, validación temporal, interpretabilidad y despliegue funcional dentro de una interfaz interactiva.

A partir del análisis organizacional realizado, se identificó que la gestión manual del inventario generaba riesgos asociados a quiebres de stock, compras urgentes, sobreinventario y dependencia excesiva de decisiones basadas únicamente en experiencia operativa. Frente a esta problemática, el proyecto demostró que el uso de inteligencia artificial aplicada puede contribuir significativamente a fortalecer procesos de planificación y abastecimiento mediante herramientas de apoyo a la decisión fundamentadas en datos históricos.

Los resultados obtenidos evidenciaron que el modelo baseline basado en promedio móvil de cuatro semanas presentó el mejor desempeño predictivo frente a los modelos complejos evaluados, alcanzando un MAE de 1.797 y un  $R^2$  de 0.583. Este comportamiento permitió concluir que, bajo las condiciones actuales del dataset y el contexto operativo de NovaPet, el comportamiento reciente del consumo constituye el principal factor explicativo de la demanda futura.

Asimismo, el proyecto confirmó que una mayor complejidad algorítmica no garantiza necesariamente mejores resultados predictivos. Aunque Random Forest y XGBoost aportaron valor experimental y metodológico, el baseline demostró mayor robustez y estabilidad dentro del escenario analizado. Esta conclusión representa uno de los principales aprendizajes técnicos del proyecto y refuerza la importancia de comparar



modelos avanzados contra referencias simples antes de adoptar soluciones de mayor complejidad.

La incorporación de técnicas de validación temporal y walk-forward validation permitió fortalecer confiabilidad metodológica y reducir riesgos asociados a fuga de información. Del mismo modo, el uso de SHAP sobre Random Forest facilitó interpretar la relevancia de variables temporales y mejorar transparencia del sistema predictivo.

Desde una perspectiva práctica, el desarrollo del prototipo funcional mediante Streamlit permitió transformar el modelo predictivo en una herramienta interactiva orientada a usuarios no técnicos. La aplicación integra funcionalidades de recomendación operativa, visualización de riesgo e interpretación básica de resultados, demostrando viabilidad de implementación dentro de contextos organizacionales reales.

Finalmente, el proyecto evidencia que la inteligencia artificial aplicada puede generar valor tangible incluso en organizaciones pequeñas o medianas cuando existe adecuada alineación entre problema organizacional, calidad de datos, validación metodológica y diseño orientado al usuario. Asimismo, resalta la importancia de mantener supervisión humana, interpretabilidad y criterios éticos dentro de sistemas inteligentes aplicados a procesos críticos de decisión.

## **9. Trabajo futuro**

Aunque el proyecto alcanzó un nivel funcional y metodológico sólido, existen diversas oportunidades de mejora orientadas a fortalecer precisión predictiva, escalabilidad e integración operativa del sistema inteligente desarrollado.

Una de las principales líneas futuras corresponde a la ampliación del histórico transaccional del Kardex institucional, permitiendo capturar patrones temporales más complejos, variaciones estacionales y comportamientos de largo plazo que actualmente no pueden ser modelados completamente debido al tamaño moderado del dataset disponible.

Asimismo, se plantea incorporar variables externas que podrían influir significativamente sobre el comportamiento de la demanda, incluyendo número de consultas veterinarias, campañas de vacunación, promociones comerciales, estacionalidad mensual y eventos extraordinarios. La integración de estas variables permitiría enriquecer el modelo y mejorar capacidad predictiva frente a escenarios dinámicos.

Desde una perspectiva organizacional, también resulta relevante medir impacto económico real posterior a una eventual implementación operativa del sistema. Entre los indicadores potenciales destacan reducción de quiebres de stock, disminución de compras urgentes, mejora en rotación de inventario y reducción de capital inmovilizado.

A nivel técnico, futuras versiones podrían incorporar mecanismos automatizados de actualización periódica y monitoreo continuo del desempeño predictivo, incluyendo reentrenamiento automático, alertas por deterioro del modelo y conexión con sistemas de gestión de inventario o ERP institucionales.



Otra línea de evolución corresponde a la ampliación del alcance predictivo hacia otros tipos de productos y consumibles críticos, en especial aquellos que actualmente se gestionan mediante reglas operativas debido a limitaciones históricas de datos.

Finalmente, se contempla continuar fortaleciendo documentación técnica, experiencia de usuario e interpretabilidad del sistema, incorporando mejoras visuales, paneles analíticos y herramientas adicionales que faciliten adopción organizacional y escalabilidad futura del prototipo.



## 10. Referencias bibliográficas

- Breiman, L. (2001). Random forests. *Machine Learning*, 45(1), 5–32. <https://doi.org/10.1023/A:1010933404324>
- Box, G. E. P., Jenkins, G. M., Reinsel, G. C., & Ljung, G. M. (2015). *Time series analysis: Forecasting and control* (5th ed.). Wiley.
- Carbonneau, R., Laframboise, K., & Vahidov, R. (2008). Application of machine learning techniques for supply chain demand forecasting. *European Journal of Operational Research*, 184(3), 1140–1154. <https://doi.org/10.1016/j.ejor.2006.12.004>
- Chen, T., & Guestrin, C. (2016). XGBoost: A scalable tree boosting system. In *Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining* (pp. 785–794). ACM. <https://doi.org/10.1145/2939672.2939785>
- Choi, T. M., Wallace, S. W., & Wang, Y. (2018). Big data analytics in operations management. *Production and Operations Management*, 27(10), 1868–1883. <https://doi.org/10.1111/poms.12838>
- Floridi, L., Cows, J., Beltrametti, M., Chatila, R., Chazerand, P., Dignum, V., Luetge, C., Madelin, R., Pagallo, U., Rossi, F., Schafer, Valcke, P., & Vayena, E. (2018). AI4People—An ethical framework for a good AI society. *Minds and Machines*, 28(4), 689–707. <https://doi.org/10.1007/s11023-018-9482-5>
- Hyndman, R. J., & Athanasopoulos, G. (2021). *Forecasting: Principles and practice* (3rd ed.). OTexts. <https://otexts.com/fpp3/>
- Lundberg, S. M., & Lee, S. I. (2017). A unified approach to interpreting model predictions. *Advances in Neural Information Processing Systems*, 30, 4765–4774.
- Makridakis, S., Spiliotis, E., & Assimakopoulos, V. (2018). The M4 competition: Results, findings, conclusion, and way forward. *International Journal of Forecasting*, 34(4), 802–808. <https://doi.org/10.1016/j.ijforecast.2018.06.001>
- Makridakis, S., Spiliotis, E., & Assimakopoulos, V. (2022). M5 accuracy competition: Results, findings, and conclusions. *International Journal of Forecasting*, 38(4), 1346–1364. <https://doi.org/10.1016/j.ijforecast.2021.11.013>
- Molnar, C. (2022). *Interpretable machine learning* (2nd ed.). Lulu.com.
- Russell, S., & Norvig, P. (2021). *Artificial intelligence: A modern approach* (4th ed.). Pearson.
- Waller, M. A., & Fawcett, S. E. (2013). Data science, predictive analytics, and big data. *Journal of Business Logistics*, 34(2), 77–84. <https://doi.org/10.1111/jbl.12010>
- Chapman, P., Clinton, J., Kerber, R., Khabaza, T., Reinartz, T., Shearer, C., & Wirth, R. (2000). *CRISP-DM 1.0: Step-by-step data mining guide*



## **11. Anexos**

[En esta sección se incluye el detalle de lo que estime no indispensable para la comprensión del tema central, pero que lo complementa. También se debe incluir todos los documentos generados por la metodología usada en el desarrollo de la solución del problema. Ejemplos: Diagramas, Detalles de desarrollos de fórmulas, de experimentos realizados, tablas de estadísticas, gráficos, copia de documentos, leyes o reglamentos que no pueden ser parafraseados, etc. Los anexos se designarán en forma secuencial numérica (Anexo 1, Anexo 2, etc.).]